《自然语言处理》第1 次作业
HW1：分词和词云可视化

March 18, 2024

姓名：刘元昊　　学号：21311223

一、实验内容

题目：

1. 数据：十六大 二十大报告全文
2. 任选一种分词工具对五个文档分别进行分词和词性标注
3. 对分词结果去停止词（停词表为该链接所提供的四个停词表的并集）并进行词频统计，在实验报告中分别列出五个文档词频最高的 30 个名词及其词频
4. 使用词云可视化工具（例如，wordcloud) 分别对每个文档词频最高的 30 个名词进行词云可视化

二、实验环境

Python版本：　3.11.4

三、实验过程和结果

合并停用词列表

- 合并四个停用词文件的内容，形成一个停用词集合。
- 函数通过逐行读取各个文件并将每行内容添加至一个集合中实现合并操作。最终将合并后的停用词集合写入新文件

文档预处理与词性标注

- 使用 jieba 的 posseg 分词模块对该文本进行分词及词性标注，并过滤掉停用词和非名词词汇。

词频统计

- 定义函数 ‘count_words(words)‘，计算经过分词和词性过滤后的单词频率，并返回按频率降序排列的前 N 个单词及其频率的元组列表。

词云生成与可视化

- 使用 WordCloud 库基于给定的词频字典生成词云图像。
- 设置词云的各项属性如字体、背景颜色、最大显示词数、宽度和高度等，并选择颜色映射方案。
- 使用 Matplotlib 进行图像展示和保存，生成的词云图片以原文件名加 “词云.png” 格式保存。

代码实现

完整代码见代码块。

```
import jieba
import jieba.posseg as pseg
from wordcloud import WordCloud
import matplotlib.pyplot as plt

# 合并 baidu_stopwords.txt cn_stopwords.txt hit_stopwords.txt
   scu_stopwords.txt 的并集，作为停止词文档
# 保存为 stopwords.txt
# 定义一个集合来存储停止词
def merge_stopwords():
    stopwords = set()

    # 定义一个列表来存储文件名
    files = ['baidu_stopwords.txt', 'cn_stopwords.txt', '
       hit_stopwords.txt', 'scu_stopwords.txt']

    # 遍历每个文件
    for file in files:
```

```
        # 打开文件
        with open(file, 'r') as f:
            # 读取文件中的每一行
            for line in f:
                # 添加到停止词集合中
                stopwords.add(line.strip())

    # 打开新的文件并写入停止词
    with open('stopwords.txt', 'w') as f:
        for word in stopwords:
            f.write(word + '\n')
# merge_stopwords()

# 加载停止词
with open('stopwords.txt', 'r', encoding='utf-8') as f:
    stopwords = set(f.read().splitlines())

# 对文档进行分词和词性标注
def segment_and_tag(text):
    words = pseg.cut(text)
    return [(word, flag) for word, flag in words if word not in
        stopwords and flag == 'n']

# 对分词结果进行词频统计
def count_words(words):
    word_counts = {}
    for word, _ in words:
        if word in word_counts:
            word_counts[word] += 1
        else:
            word_counts[word] = 1
    return sorted(word_counts.items(), key=lambda x: x[1], reverse=
        True)

# 对词频最高的30个名词进行词云可视化
def visualize_wordcloud(word_counts,filename):
    # wordcloud = WordCloud(font_path = '/System/Library/Fonts/
        PingFang.ttc',background_color='white',width=).
        generate_from_frequencies(dict(word_counts[:30]))
    wordcloud = WordCloud(
```

```
        # font_path='/System/Library/Fonts/PingFang.ttc',
        font_path='/System/Library/Fonts/Supplemental/Songti.ttc',
        background_color='white',
        max_words=100,
        width=800,
        height=400,
        contour_width=3,
        # colormap='autumn'
        colormap='hsv'
    ).generate_from_frequencies(dict(word_counts[:30]))
    plt.imshow(wordcloud, interpolation='bilinear', aspect='auto')
    plt.axis('off')
    plt.savefig(filename[:-4]+'词云.png', dpi = 600, bbox_inches='
        tight', pad_inches=0.5, transparent=True)
    # plt.show()


import os

# 定义目录路径
directory = './document/'

# 遍历目录中的每个文件
for filename in os.listdir(directory):
    # 拼接文件路径
    filepath = os.path.join(directory, filename)
    # 打开并读取文件
    with open(filepath, 'r') as f:
        text = f.read()
    words = segment_and_tag(text)
    word_counts = count_words(words)
    print(f'{filename} top 30 nouns: {word_counts[:30]}')
    visualize_wordcloud(word_counts,filename)
```

实验结果

得到结果如图 1 所示，可见五个文档词频最高的 30 个名词及其词频：

- 十六大报告全文: [(' 社会主义', 118), (' 党', 110), (' 人民', 98), (' 经济', 84), (' 文化', 72), (' 社会', 68), (' 制度', 58), (' 政治', 47), (' 思想', 46), (' 国家', 41), (' 领导', 38), (' 群众', 34), (' 民主', 33), (' 世界', 32), (' 特色', 30), (' 基础', 30), (' 干部', 30), (' 市场', 29), (' 民族', 29), (' 事业', 28), (' 理论', 26), (' 体系', 23), (' 国际', 23), (' 水平', 22), (' 关系', 21), (' 全国', 20), (' 精神', 20), (' 政策', 19), (' 方针', 18), (' 企业', 18)]

- 十七大报告全文: [(' 社会主义', 148), (' 人民', 109), (' 社会', 98), (' 党', 73), (' 制度', 71), (' 特色', 64), (' 经济', 61), (' 文化', 59), (' 科学', 51), (' 民主', 45), (' 国家', 41), (' 政治', 39), (' 体系', 38), (' 群众', 31), (' 世界', 30), (' 关系', 28), (' 事业', 26), (' 干部', 26), (' 马克思主义', 25), (' 市场', 24), (' 国际', 23), (' 农村', 23), (' 领导', 22), (' 小康社会', 21), (' 思想', 21), (' 战略', 21), (' 军队', 21), (' 能力', 20), (' 基层', 20), (' 党员', 20)]

- 十八大报告全文: [(' 社会主义', 165), (' 人民', 112), (' 特色', 93), (' 社会', 90), (' 制度', 85), (' 文化', 78), (' 经济', 73), (' 党', 67), (' 国家', 54), (' 体系', 47), (' 民主', 47), (' 科学', 41), (' 政治', 40), (' 机制', 33), (' 能力', 32), (' 水平', 29), (' 道路', 27), (' 关系', 27), (' 生态', 27), (' 世界', 27), (' 群众', 27), (' 国际', 26), (' 城乡', 25), (' 基层', 25), (' 事业', 25), (' 干部', 25), (' 战略', 25), (' 方式', 22), (' 基础', 21), (' 领导', 21)]

- 十九大报告全文: [(' 人民', 157), (' 社会主义', 147), (' 党', 112), (' 国家', 90), (' 制度', 83), (' 特色', 80), (' 社会', 80), (' 政治', 80), (' 体系', 68), (' 文化', 66), (' 时代', 64), (' 经济', 59), (' 民主', 44), (' 战略', 36), (' 领导', 36), (' 世界', 34), (' 生态', 32), (' 法治', 31), (' 思想', 30), (' 民族', 29), (' 能力', 27), (' 历史', 27), (' 全党', 25), (' 群众', 25), (' 国际', 24), (' 人类', 23), (' 理论', 22), (' 事业', 21), (' 机制', 21), (' 协商', 21)]

- 二十大报告全文: [(' 社会主义', 83), (' 人民', 75), (' 国家', 60), (' 体系', 45), (' 党', 39), (' 时代', 34), (' 特色', 33), (' 战略', 32), (' 制度', 24), (' 文化', 23), (' 社会', 23), (' 世界', 21), (' 民主', 19), (' 政治', 19), (' 强国', 18), (' 思想', 17), (' 精神', 17), (' 事业', 17), (' 领导', 17), (' 国际', 17), (' 经济', 16), (' 历史', 14), (' 马克思主义', 14), (' 人才', 14), (' 人类', 13), (' 法治', 13), (' 格局', 11), (' 全球', 11), (' 道路', 11), (' 群众', 11)]



Figure 1: 程序运行结果



(a): 十六大报告的词云



(b): 十七大报告的词云



(c): 十八大报告的词云



(d): 十九大报告的词云



(e): 二十大报告的词云

Figure 2: 十六到二十大报告词云可视化

结果分析

在本次实验中，通过对各份报告中出现次数最多的前 30 个名词的统计，我们可以得出如下初步结论：

- 核心主题的一致性：从各份报告中频繁出现的名词可以看出，“社会主义”、“人民”、“党”、“国家”、“社会”、“制度”、“文化”、“经济”、“民主” 等核心词汇是长久一致的。
- 关注点的变化：例如，“市场经济”、“小康社会”、“军队”、“基层”、“党员” 等词语在不同报告中出现的频次有所变化，这反映出我国在不同阶段的工作重点和着力点的不同。

四、实验总结

在本次实验中，我们对十六到二十大报告进行文本挖掘分析，利用 jieba 库进行分词和词性标注，并结合自定义的停用词表过滤掉常见的停用词，重点关注名词出现的频率。本次实验加强了我对学科的理解和 NLP 的代码能力，巩固了基础知识，使我受益良多。

References

[1] Matplotlib 库,

Available:https://matplotlib.org/

[2] 中文常用停用词表（哈工大停用词表、百度停用词表等）

Available:https://github.com/goto456/stopwords

[3] WordCloud

Available:http://amueller.github.io/word_cloud/index.html